FinComercial, S.A.

Analítica inteligente para anticipar el riesgo

REPORTE COMPARATIVO · ACTIVIDAD 4

FinPredict NLP

Evaluación de modelos preentrenados para identificación temprana de señales de riesgo hipotecario

Propósito del documento

Comparar tres estrategias de NLP preentrenado bajo un protocolo reproducible, cuantificar el trade-off entre calidad y eficiencia y emitir una recomendación técnicamente sustentada para la prueba de concepto.

ORGANIZACIÓN	FinComercial, S.A.
RESPONSABLE	Lizbeth Bruno Lorenzana · AI Lead
ASIGNATURA	Gestión de Proyectos de Inteligencia Artificial
FECHA	11/10/2026
VERSIÓN	1.0 · Entrega final Actividad 4

Repositorio técnico: github.com/lizlorenzana931109-art/finpredict-nlp

1. Resumen ejecutivo

Síntesis de la decisión técnica y su lectura de negocio.

2,000	3	1,930	74.25 %
registros sintéticos	estrategias comparadas	registros de evaluación final	accuracy del modelo recomendado

Problema	Las señales de deterioro financiero pueden aparecer en las conversaciones con clientes antes de reflejarse en variables estructuradas de pago.
Solución evaluada	Clasificación zero-shot de textos en SEÑAL_RIESGO vs. SIN_SEÑAL_RIESGO mediante modelos preentrenados de Hugging Face.
Resultado	BART + traducción obtuvo el mejor desempeño global: 74.25 % accuracy, 66.01 % precision de riesgo, 100 % recall y 72.42 % F1 macro.
Trade-off	La mayor calidad implica mayor costo computacional: 61.41 ms por registro frente a 10.82 ms de mDeBERTa y 5.13 ms de SELECTRA.
Recomendación	Usar BART + traducción como referencia para la prueba de concepto; mDeBERTa queda como alternativa si la prioridad cambia hacia eficiencia.
Condición	No automatizar decisiones sobre clientes. El prototipo debe operar como priorizador con revisión humana y avanzar a validación con datos representativos.
	Decisión ejecutiva BART + traducción es la opción de mayor calidad para el prototipo, pero la precisión de 66.01 % todavía implica falsos positivos relevantes. La recomendación es continuar a una fase de validación y ajuste, no a producción automática.

2. Caso de uso y diseño experimental

Diseño orientado a comparar modelos bajo condiciones equivalentes y evitar ajustes sobre el conjunto final.

CASO DE USO

- Identificar señales tempranas de dificultad de pago en textos de atención y gestión hipotecaria.
- Clases: SEÑAL_RIESGO / SIN_SEÑAL_RIESGO.
- Uso previsto: priorización preventiva con revisión humana.

DATASET

- 2,000 registros sintéticos y balanceados: 1,000 por clase.
- Variables de dificultad lingüística y lenguaje local.
- Sin datos personales ni información real de clientes.

PROTOCOLO EXPERIMENTAL

10	60	1,930
Piloto	**Calibración**	**Evaluación final**
Exploración inicial	Selección semántica	Comparación definitiva

AJUSTE MÍNIMO APLICADO

No se realizó fine-tuning. Se compararon tres formulaciones semánticas (V1, V2 y V3) sobre un conjunto de calibración independiente. La configuración V2 fue seleccionada como configuración común y quedó congelada antes de la evaluación final.

Configuración común V2

“dificultad actual de pago” vs. “ausencia de dificultad actual de pago”. Esta decisión reduce el riesgo de favorecer a un modelo mediante ajustes específicos posteriores.

3. Selección de modelos y ecosistema Hugging Face

Tres estrategias técnicamente distintas para contrastar idioma, capacidad y costo operativo.

Estrategia	Modelo	Idioma	Tamaño aprox.	Licencia	Recursos
Español	Recognai/ zeroshot_selectra_medium	Español	40.8M	Apache-2.0	Bajos
Multilingüe	MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7	27 idiomas / NLI multilingüe	0.3B	MIT	Medios
Inglés + traducción	facebook/bart-large-mnli + Helsinki-NLP/opus-mt-es-en	Inglés + ES→EN	0.4B BART + traductor	MIT + Apache-2.0	Altos

CRITERIOS DE PRESELECCIÓN

- **Adecuación al caso de uso:** 20 %.
- **Capacidad lingüística:** 20 %.
- **Evidencia técnica disponible:** 15 %.
- **Recursos, tamaño y latencia esperada:** 30 % en conjunto.
- **Licencia, documentación e integración:** 15 % en conjunto.

ECOSISTEMA UTILIZADO

Hugging Face Hub y Model Cards se utilizaron para localizar y revisar modelos; Transformers para los pipelines de inferencia; autenticación de lectura para acceso al Hub. Spaces se identificó como alternativa de demostración futura, pero no era necesario para el alcance del prototipo.

Razonamiento de la selección

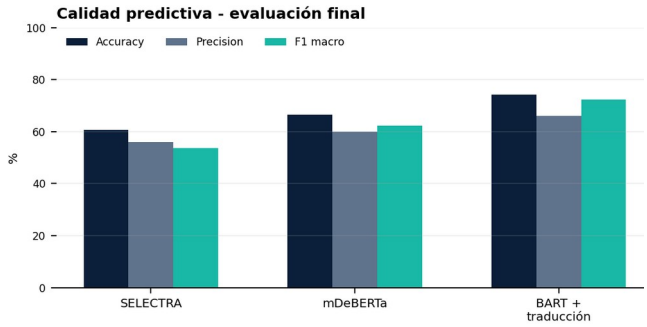
SELECTRA representa especialización en español y eficiencia; mDeBERTa representa cobertura multilingüe y mayor capacidad; BART + traducción representa una estrategia más costosa que permite evaluar si una cadena en inglés compensa su complejidad con mayor calidad.

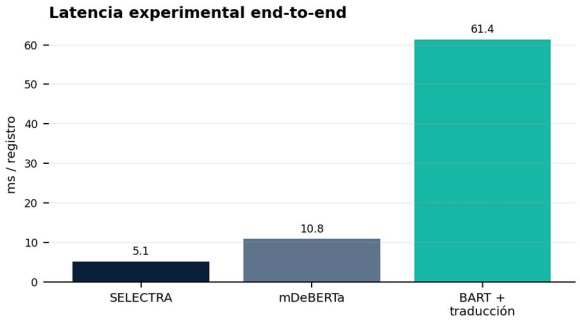
Fuente técnica: Model Cards de Hugging Face; tamaños y licencias verificados en las referencias al final del documento.

4. Resultados comparativos

Evaluación final sobre 1,930 registros bajo la configuración V2 común.

Modelo	Accuracy	Precision riesgo	Recall riesgo	F1 riesgo	F1 macro	Latencia	Throughput
SELECTRA	60.73 %	56.02 %	99.79 %	71.76 %	53.65 %	5.13 ms	194.83 reg/s
mDeBERTa	66.42 %	59.83 %	100.00 %	74.86 %	62.16 %	10.82 ms	92.42 reg/s
BART + traducción	74.25 %	66.01 %	100.00 %	79.52 %	72.42 %	61.41 ms	16.28 reg/s





Lectura ejecutiva

BART + traducción gana en calidad; SELECTRA gana en eficiencia; mDeBERTa queda en una posición intermedia. Como los tres modelos presentan recall cercano o igual al 100 %, precision y F1 macro son especialmente útiles para diferenciar la carga de falsos positivos.

5. Robustez lingüística

La recomendación se contrasta frente a lenguaje local y distintos niveles de dificultad.

F1 MACRO POR LENGUAJE

Modelo	Estándar	Local
SELECTRA	0.5376	0.5320
mDeBERTa	0.6238	0.6127
BART + traducción	0.7191	0.7442

Contrario a la hipótesis inicial, BART + traducción no perdió desempeño en los 386 registros con lenguaje local; su F1 macro subió de 0.7191 a 0.7442. El resultado se limita al dataset sintético y no debe generalizarse a toda variación regional del español.

F1 MACRO POR DIFICULTAD LINGÜÍSTICA

Dificultad	SELECTRA	mDeBERTa	BART + traducción
Baja	0.4124	0.4574	**0.6131**
Media	0.4885	0.5761	**0.6752**
Alta	0.5466	0.6588	**0.7519**

Interpretación metodológica

BART + traducción mantiene el mejor F1 macro en los tres segmentos. La dificultad fue definida mediante reglas lingüísticas; por ello, esta segmentación se interpreta como evidencia complementaria y no como una escala absoluta de complejidad para cada arquitectura.

6. Trade-offs y recomendación

Selección basada en métricas, restricciones operativas y objetivo real del caso de uso.

Dimensión	SELECTRA	mDeBERTa	BART + traducción
Calidad global	Baja relativa	Intermedia	**Mejor**
Recall riesgo	99.79 %	100 %	**100 %**
F1 macro	53.65 %	62.16 %	**72.42 %**
Latencia	5.13 ms	10.82 ms	**61.41 ms**
Complejidad	1 modelo	1 modelo	**Traductor + clasificador**
Uso recomendado	Alta velocidad	Equilibrio	**POC orientada a calidad**

Modelo recomendado: BART + traducción

Se recomienda como referencia para la prueba de concepto porque lidera en accuracy, precision, F1 de riesgo, F1 macro y análisis segmentados. Su mayor latencia es aceptable en un escenario de procesamiento asíncrono o por lotes, pero debe considerarse en cualquier arquitectura productiva.

ARQUITECTURA RECOMENDADA

Texto en español → Helsinki-NLP ES→EN → BART-MNLI → Priorización → Revisión humana

mDeBERTa queda como segunda opción si el proyecto prioriza menor latencia, menor complejidad y procesamiento directo del español. SELECTRA es la alternativa más eficiente, pero su menor precision incrementa el volumen de alertas incorrectas.

Límite de la recomendación

La estrategia recomendada no debe activar decisiones adversas, cambios contractuales ni acciones automáticas sobre clientes. El modelo sólo prioriza; Riesgo y Operaciones deciden.

7. Ajuste mínimo, umbrales y condición de continuidad

Separación entre una POC válida y una solución lista para producción.

AJUSTE MÍNIMO REALIZADO

El único ajuste del prototipo fue semántico: comparación de etiquetas y templates zero-shot sobre un conjunto de calibración independiente. No hubo fine-tuning ni optimización posterior sobre los 1,930 registros finales.

CRITERIOS PROPUESTOS PARA UNA SIGUIENTE FASE

Indicador	Resultado actual BART	Umbral propuesto*	Lectura
Recall riesgo	100.00 %	≥ 95 %	Cumple
Precision riesgo	66.01 %	≥ 75 %	No cumple
F1 macro	72.42 %	≥ 75 %	No cumple
Revisión humana	Obligatoria	Obligatoria	Cumple

** Umbrales de aceptación propuestos para pilotaje con datos representativos; deben ser validados con Riesgo y Operaciones. No son umbrales de probabilidad del modelo.*

Estado de preparación

GO para continuar a validación / ajuste controlado. NO-GO para automatización productiva. La precision actual implica aproximadamente un falso positivo por cada tres alertas positivas, por lo que aún existe costo operativo relevante.

Los scores de zero-shot no se interpretan como probabilidades calibradas. Por ello, no se define un corte operativo sobre el score en esta fase; la calibración de probabilidades y el thresholding deben realizarse posteriormente con datos reales y un objetivo de negocio explícito.

8. Riesgos y controles

Riesgos relevantes para evolucionar el prototipo sin confundir desempeño experimental con capacidad productiva.

Riesgo	Impacto	Control / mitigación
Falsos positivos	Carga operativa y contacto innecesario	Ajuste/fine-tuning, calibración y revisión humana antes de actuar.
Falsos negativos	Pérdida de oportunidades preventivas	Monitorear recall por segmento y definir umbral mínimo de continuidad.
Dataset sintético	Brecha entre POC y conversaciones reales	Piloto con datos anonimizados/representativos y holdout independiente.
Pérdida semántica en traducción	Clasificación incorrecta de expresiones regionales	Validación cualitativa, métricas por segmento y monitoreo de lenguaje local.
Sesgo / variación lingüística	Desempeño desigual entre grupos o formas de expresión	Cobertura lingüística, análisis por segmento, gobierno y supervisión.
Privacidad y seguridad	Exposición de información financiera o personal	Minimización de datos, controles de acceso, trazabilidad y arquitectura aprobada.

Principio de gobierno

El modelo es un componente de apoyo. Toda acción sensible conserva supervisión humana, trazabilidad de la señal y capacidad de revisión. El valor del sistema depende tanto del desempeño técnico como de la capacidad operativa para responder a las alertas.

SIGUIENTE DECISIÓN

Autorizar una fase de validación controlada con datos representativos, análisis detallado de errores, fine-tuning o ajuste supervisado, calibración y definición conjunta de umbrales con Riesgo y Operaciones.

9. Declaración de uso de IA generativa y trazabilidad

Transparencia sobre el uso de ChatGPT como herramienta de apoyo durante el desarrollo.

Se utilizó ChatGPT como herramienta de asistencia durante el proyecto. No se utilizaron sus respuestas como evidencia experimental ni como sustituto de la ejecución de los modelos. Las métricas reportadas provienen de los notebooks ejecutados en Google Colab.

Uso de ChatGPT	Aplicación en el proyecto	Validación realizada
Desarrollo de código	Apoyo para estructurar, revisar y depurar código Python/Colab del dataset, inferencia y evaluación.	El código fue ejecutado, corregido y validado en Colab.
Exploración de modelos	Apoyo para organizar criterios de búsqueda, comparar alternativas y revisar la lógica de selección.	La selección se contrastó con Model Cards de Hugging Face y resultados experimentales.
Usabilidad de GitHub	Apoyo para estructurar el repositorio, README, requirements y organización de evidencias.	La estructura final fue implementada y verificada en el repositorio.
Documentación técnica	Apoyo en síntesis, redacción y estructuración del reporte comparativo.	La autora revisó la coherencia con notebooks, CSV y objetivos de la actividad.

Responsabilidad de autoría

Las decisiones metodológicas, la ejecución del experimento, la revisión de resultados, la selección final del modelo y la entrega académica permanecen bajo responsabilidad de la autora. No se incluyen prompts porque no forman parte de los requisitos de esta actividad.

EVIDENCIA DISPONIBLE EN GITHUB

Ruta	Evidencia
data/	Dataset sintético y documentación.
docs/model_selection.md	Criterios, matriz y justificación de candidatos.
notebooks/00_dataset_generation_validation.ipynb	Generación y validación del dataset.
notebooks/01_model_comparison.ipynb	Calibración, inferencia, métricas y recomendación.
results/	CSV con métricas globales y segmentadas.
src/data_generation.py	Generación reproducible del dataset.
requirements.txt	Dependencias del entorno.

Repositorio: https://github.com/lizlorenzana931109-art/finpredict-nlp

10. Conclusiones

Cierre de la comparación y criterio de continuidad del prototipo.

- **1.** La comparación cumple el objetivo de contrastar tres estrategias preentrenadas bajo un protocolo común y reproducible.
- **2.** BART + traducción obtiene la mejor calidad global y segmentada, pero su latencia es sustancialmente mayor.
- **3.** mDeBERTa representa la alternativa de mejor equilibrio cuando eficiencia y simplicidad operativa pesan más.
- **4.** El recall de 100 % no elimina el riesgo: la precision de 66.01 % demuestra que los falsos positivos siguen siendo un reto relevante.
- **5.** La POC justifica continuar con validación y ajuste, pero no respalda automatización productiva ni decisiones autónomas sobre clientes.

Conclusión ejecutiva

FinPredict NLP demuestra que las señales textuales pueden convertirse en un insumo útil de priorización. El siguiente valor no proviene de añadir más modelos, sino de validar el enfoque con datos representativos, mejorar precision y gobernar la integración con procesos humanos.

REFERENCIAS

Helsinki-NLP. (s. f.). opus-mt-es-en [Model card]. Hugging Face. https://huggingface.co/Helsinki-NLP/opus-mt-es-en

Laurer, M. (s. f.). mDeBERTa-v3-base-xnli-multilingual-nli-2mil7 [Model card]. Hugging Face. https://huggingface.co/MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7

Meta AI. (s. f.). facebook/bart-large-mnli [Model card]. Hugging Face. https://huggingface.co/facebook/bart-large-mnli

Recognai. (s. f.). zeroshot_selectra_medium [Model card]. Hugging Face. https://huggingface.co/Recognai/zeroshot_selectra_medium

FinPredict NLP. (2026). Repositorio técnico del proyecto. GitHub. https://github.com/lizlorenzana931109-art/finpredict-nlp

FinComercial, S.A. · FinPredict NLP · Actividad 4